

How the Yettel Bulgaria dataset was created

Short answer: We built a synthetic Bulgarian multi-hop RAG benchmark from publicly available Yettel Bulgaria corporate web pages. The documents are real public prose; the evaluation questions, answers, and gold evidence links were generated with GPT-5.4-mini and then automatically validated.

Simple pipeline

1. Discover: read the public Yettel Bulgaria corporate sitemap and download each listed HTML page.
2. Clean: extract the main article prose; remove navigation, headers, footers, tables, figures, forms, media, and scripts.
3. Filter: retain unique Bulgarian pages containing 1,500–5,000 cl100k_base tokens, then deterministically select 340 documents.
4. Chunk: split each document into 1,024-token chunks with 128-token overlap, producing 963 chunks with stable IDs.
5. Create evaluation QA: group related documents and ask GPT-5.4-mini to create Bulgarian inference, comparison, temporal, and unanswerable questions.
6. Validate and label: require verbatim evidence spans, map each span to canonical document/chunk IDs, reject invalid or duplicate outputs, and save the gold labels.

Documents	340	Chunks	963
Questions	2,556	Evidence-bearing	2,255
Null questions	301	Language	Bulgarian

Important: This is a research dataset created from Yettel's public pages; it is not an official dataset released or endorsed by Yettel. The date field is the sitemap's last-modified value, not necessarily the publication date.

Small sample of the dataset

Document ID	yettel_bg_0001
Title	Yettel отчита двуцифрени ръстове в предварителните поръчки на новите устройства на Apple спрямо 2024
Category / language	news / bg
Source URL	https://www.yettel.bg/bg/news/yettel-otchita-dvucifreni-rstove-v-predvaritelnite-porchki-na-novite-ustroystva-na-apple-spramo-2024
Length	2,476 tokens
Body excerpt	• Най-поръчваният модел смартфон е iPhone Pro в цвят Deep Blue с 256 GB памет • Предварителните заявки за премиум серията Apple Watch Ultra 3 отбелязват ръст от над 160% в сравнение с Apple Watch Ultra 2 • Близко 90% от всички поръчани смартчасовници са с LTE функционалност Yettel отчита над 10% ръст в предварителните поръчки на новите модели от серията iPhone 17 спрямо миналогодишните iPhone 16 устройства. По общ брой заявени устройства води iPhone 17 Pro Max линията, но най-поръчваният модел смартфон в мрежата на Yettel е iPhone 17 Pro 256 GB Deep Blue. За сравнение, миналогодишният фаворит на клиентите на телек...
Chunk ID	yettel_bg_0001::c00
Token range	0–1024 (1024 tokens)

Chunk excerpt	• Най-поръчваният модел смартфон е iPhone Pro в цвят Deep Blue с 256 GB памет • Предварителните заявки за премиум серията Apple Watch Ultra 3 отбелязват ръст от над 160% в сравнение с Apple Watch Ultra 2 • Близко 90% от всички поръчани смартчасовници са с LTE функционалност Yettel отчита над 10% ръст в предварителните поръчки на новите модели от серията iPhone 17 спрямо миналогодишните iPhone 16 устройства. По общ бро...
---------------	---

Example evaluation record

Query ID / type	yq00000 / temporal_query
Question	Кой продукт първо бе представен през пролетта и как се променя предлагането му по-късно спрямо по-ранната оферта в Yettel?
Answer	Първоначално продуктът се предлага с HUAWEI Watch GT 3, а по-късно е в комплект с допълнителна каишка.
Gold evidence	• yettel_bg_0176::c01 — “Изисканият смарт часовник бе представен тази пролет” • yettel_bg_0147::c00 — “до края на януари” • yettel_bg_0232::c00 — “От 9 до 21 май” • yettel_bg_0235::c00 — “До 31 август”

The PDF shows shortened excerpts for readability. The machine-readable files retain the full document text, complete chunks, metadata, answers, and evidence mappings.